

Estudo de Caso: Otimização de Compras e Fornecedores

João Paulo Martins Rodrigues

Contexto

Você está atuando como analista sênior de dados na área de **Compras** de uma empresa de manufatura. A diretoria quer entender como otimizar os custos com fornecedores e melhorar a eficiência do processo de compras.

Você tem acesso a um dataset com as seguintes colunas:

- data_pedido: data do pedido
- id_fornecedor: identificador do fornecedor
- categoria_material: tipo de material comprado
- valor_unitario: valor por unidade
- quantidade: quantidade comprada
- prazo_entrega_dias: dias entre pedido e entrega
- nota_qualidade: avaliação da entrega (1 a 5)
- urgente: se o pedido foi urgente (sim/não)
- responsavel_compra: comprador responsável

Ferramentas Utilizadas:

Docker

Spark

Hadoop - HDFS

O Estudo de caso foi feito em máquina local, com containers Docker do Spark e Jupyternotebook.

O código está disponível aqui:

https://github.com/joaopmts/lab/blob/main/spark/jupyter_home/notebooks/Vivo/estudo_de_caso_vivo.ipynb

Desafio

Você deve analisar os dados e responder às seguintes perguntas:



Parte 1: Diagnóstico

1. Quais fornecedores apresentam maior custo total? E quais têm melhor custo-benefício?
2. Existe relação entre urgência do pedido e aumento de custo?
3. Quais categorias de materiais têm maior impacto no orçamento?



Parte 2: Modelagem e Otimização

4. Crie um modelo simples para prever o custo total de um pedido com base nas variáveis disponíveis.
5. Quais variáveis mais influenciam o custo?
6. Que recomendações você faria para reduzir custos e melhorar a eficiência?



Parte 3: Estratégia e Comunicação

7. Como você apresentaria esses insights para o time de compras e diretoria?
8. Que indicadores você sugeriria acompanhar mensalmente?



O que iremos avaliar:

- Capacidade de análise crítica e priorização de problemas
- Conhecimento em modelagem preditiva e estatística
- Visão de negócio aplicada à área de compras
- Clareza na comunicação de insights
- Proatividade em sugerir melhorias operacionais

Passo a passo

Análise Exploratória:

Primeiro, realizei uma análise exploratória para entender mais a minha base de dados. Para obter informações como tamanho da base, quantidade de nulos, metadados das colunas.

Nela observei que, temos 200 linhas, das quais nenhuma coluna tem valor nulo, utilizando o spark, na importação do HDFS, pedi para ele inferir o schema delas, então, meu ponto de atenção foi para a coluna data que estava como string e queria que ela ficasse como date.

```
df.describe().show()
```

	data_pedido	id_fornecedor	categoria_material	valor_unitario	quantidade	prazo_entrega_dias	nota_qualidade	urgente	responsavel_compra
count	200	200	200	200	200	200	200	200	200
mean	NULL	NULL	NULL	539.1267	50.645	13.22	2.91	NULL	NULL
stddev	NULL	NULL	NULL	308.3052620115818	29.28715867605771	8.581363469459554	1.4325364930849407	NULL	NULL
min	01/02/2023	F001	componentes eletr...	20.73	1	1	1	não	Ana
max	31/05/2023	F020	Serviços	999.72	99	29	5	sim	Eduardo

Após, agrupei dados não numéricos que seriam relevantes para a análise, como categoria do material, urgência e responsável pela compra, para verificação de quantas e quais categorias temos para futura criação de variáveis dummies para o modelo de regressão linear.

categoria_material	qtd	urgente	qtd	responsavel_compra	qtd
Componentes eletrônicos	39			Bruno	40
Embalagens	35			Daniela	44
Ferramentas	43	sim	35	Carlos	38
Matéria-prima	45	não	165	Ana	42
Serviços	38			Eduardo	36

Fiz a criação da coluna total, que consiste na multiplicação da quantidade de itens por valor unitário para cada linha e deixei os valores da coluna urgente para binário entre 0 e 1, sendo 0 para não e 1 para sim. Isso nos ajudará na criação do modelo de machine learning de regressão linear.

Verifiquei que temos 20 fornecedores distintos na base, e que se criássemos variáveis dummy para cada um, o modelo não ficaria legal por poucos dados, então desconsideramos ele para o uso na regressão, apesar de ser uma variável importante num contexto de big data.

```
df.select(F.countDistinct("id_fornecedor")).show()
```

count(DISTINCT id_fornecedor)
20

1 - Análise Diagnóstica:

A.1 - Para custos totais os fornecedores F015, F003, F012, F016 E F011 representam os maiores custos. Representando quase **35% dos gastos**.

id_fornecedor	total	% total	custo_beneficio
F015	461364.9	8.57	233.37
F003	422869.5	7.86	227.96
F012	346828.35	6.44	211.61
F016	332957.01	6.19	368.72
F011	307856.62	5.72	194.85

A.2 - Analisando custo-benefício, temos uma visão um pouco diferente. Para calcular, temos algumas variáveis que podem distorcer nossa visão, como, uma empresa com grande número de faturamento ou quantidade de produtos. Por isso criei uma média ponderada da qualidade e uma média ponderada do valor por unidade, e assim dividi uma pela outra. Assim obtive as 5 melhores com custo-benefício equiparado.

id_fornecedor	total	avg_qual	custo_beneficio
F018	89645.16	3.11	80.83
F019	213031.33	3.28	122.93
F007	292941.18	3.12	136.38
F005	191870.01	2.35	140.36
F009	293442.36	3.57	145.34

B - Olhando para uma relação entre urgência e pedidos, fiz o cálculo de custo médio por pedido para os grupos de urgente e não urgentes. Pude verificar que os pedidos urgentes têm em média um custo **13% maior** que não urgentes.

urgente	qtd_pedidos	media_custo	custo_total
1	35	29762.839142857145	1041699.3700000001
0	165	26307.74127272727	4340777.31

C - Comparando categorias, as categorias com maior impacto no orçamento são: Serviços e Ferramentas com quase **50% dos custos** para o setor.

categoria_material	total
Serviços	1340234.34
Ferramentas	1317397.48
Matéria-prima	1092419.9300000002
Componentes eletrônicos	909974.12999999998
Embalagens	722450.79999999999

2 - Modelagem e Otimização:

A - Utilizando a biblioteca do pyspark mllib, criei um modelo de machine learning de regressão linear, aplicando 70% da base como fit para treino e depois testando com os outros 30% restantes para ver a aderência.

Algumas colunas como data_pedido, id_fornecedor e valor_unitario não foram consideradas no treinamento. Desconsidere a data pois o modelo não lida bem com esse tipo de dado, id_fornecedor por acabar prejudicando o modelo e valor unitário por acabar mascarando o resultado do modelo, sendo mais assertivo pois ele teria já o valor total pela quantidade * valor unitário.

features	label	prediction
(14,[0,1,2,3,5,10],[21.0,8.0,5.0,1.0,1.0,1.0])	13062.84	12488.274708746798
(14,[0,1,2,3,5,10],[79.0,13.0,4.0,1.0,1.0,1.0])	63892.83	42530.40533775864
(14,[0,1,2,3,6,11],[39.0,7.0,4.0,1.0,1.0,1.0])	18293.34	19514.230008030936
(14,[0,1,2,3,6,12],[44.0,25.0,5.0,1.0,1.0,1.0])	43399.4	32727.66997894523
(14,[0,1,2,3,7,9],[34.0,5.0,3.0,1.0,1.0,1.0])	20987.52	17030.81675933684
(14,[0,1,2,3,7,10],[34.0,11.0,1.0,1.0,1.0,1.0])	22511.74	16793.91894309849
(14,[0,1,2,3,7,11],[87.0,21.0,2.0,1.0,1.0,1.0])	86394.48	38053.54424493236
(14,[0,1,2,3,7,13],[1.0,28.0,2.0,1.0,1.0,1.0])	986.77	-4020.313315599905
(14,[0,1,2,3,8,13],[50.0,12.0,3.0,1.0,1.0,1.0])	17870.5	24478.492375419257
(14,[0,1,2,4,9],[22.0,29.0,5.0,1.0,1.0])	6174.740000000001	13141.706677527414

Aqui podemos ver a coluna label, que é o preço original da base de dados e a coluna prediction que é o preço calculado pela regressão linear. Temos algumas métricas interessantes para avaliar o modelo como:

R2 – Variação do modelo em proporção (quanto maior melhor)

RMSE – Valor médio absoluto do erro do modelo (quanto menor melhor)

R2: 0.26

RMSE: 20.158

Com esse modelo, não tivemos bons resultados com a base de teste. Testei outros modelos como random forest mas o resultado não foi satisfatório, acredito que devido a pouca quantidade de dados.

Teste com Random Forest com Cross Validation

features	label	prediction
(14,[0,1,2,3,5,10],[21.0,8.0,5.0,1.0,1.0,1.0])	13062.84	6678.214925925927
(14,[0,1,2,3,5,10],[79.0,13.0,4.0,1.0,1.0,1.0])	63892.83	39833.8470857143
(14,[0,1,2,3,6,11],[39.0,7.0,4.0,1.0,1.0,1.0])	18293.34	16593.578249999995
(14,[0,1,2,3,6,12],[44.0,25.0,5.0,1.0,1.0,1.0])	43399.4	23771.400655555553
(14,[0,1,2,3,7,9],[34.0,5.0,3.0,1.0,1.0,1.0])	20987.52	21033.999285714286
(14,[0,1,2,3,7,10],[34.0,11.0,1.0,1.0,1.0,1.0])	22511.74	14330.012952380954
(14,[0,1,2,3,7,11],[87.0,21.0,2.0,1.0,1.0,1.0])	86394.48	38974.868355158724
(14,[0,1,2,3,7,13],[1.0,28.0,2.0,1.0,1.0,1.0])	986.77	10401.082833333332
(14,[0,1,2,3,8,13],[50.0,12.0,3.0,1.0,1.0,1.0])	17870.5	18559.353449999995
(14,[0,1,2,4,9],[22.0,29.0,5.0,1.0,1.0])	6174.740000000001	17249.797194444443

R2: 0.18

RMSE: 21.257

Também fiz um teste colocando um novo registro para calcular o preço com os seguintes parâmetros

Quantidade:100

Prazo: 29

Qualidade: 5

Urgente:1

Material de Embalagem

Responsável: Carlos

features	prediction
(14,[0,1,2,3,5,11...]	47768.054399086366

O valor estimado foi de R\$47.768

B - Pedindo ao modelo quais variáveis mais influenciam o custo temos algumas como:

O tipo do material ser ferramenta e Serviços

Daniela, Bruno e Ana como responsável de compras

Os que diminuem o preço:

Carlos e Eduardo como responsável de compras

Materiais eletrônicos

```
quantidade : 524.0751218217761
prazo_entrega_dias : 124.73794296511669
nota_qualidade : 977.9161514767505
urgente : -434.3284752400508
categoria_material_Componentes eletrônicos : -4306.624531053758
categoria_material_Embalagens : -2352.662929429547
categoria_material_Ferramentas : 5084.246007352676
categoria_material_Matéria-prima : -1322.5445017492882
categoria_material_Serviços : 2514.471155967961
responsavel_compra_Bruno : 2318.437564173091
responsavel_compra_Daniela : 3288.9443930975403
responsavel_compra_Carlos : -5452.707342750644
responsavel_compra_Ana : 1917.1578942059166
responsavel_compra_Eduardo : -3329.2700273659802
```

C - Recomendações:

Renegociar contratos de serviços e ferramentas

Treinamento dos compradores e um workshop com os compradores mais eficientes (Carlos e Eduardo), compartilhando suas técnicas e processos.

Com uma base maior, pode-se verificar também os fornecedores

Automações de processos para alertas de possíveis fraudes, baixa qualidade ou urgência.

3 - Estratégia e Comunicação:

A - Apresentação para executivos:

Dashboard executivo com indicadores de custos por fornecedores, urgência, categorias e evolução mensal dos custos.

Gráficos comparativos para mostrar onde estão os maiores impactos nas áreas e possíveis otimizações de custo

Simulação, mostrando com uma gestão mais eficiente como estes custos podem diminuir.

B - KPIs para acompanhamento:

Custos por fornecedores e categoria

Monitoramento de quantidade de pedidos urgentes

Custos médios por pedidos (com quebras de categorias e urgências)

Notas de qualidade, outliers e red flags para monitoramento de fraudes por fornecedor

Índice de renegociação e planejamentos mostrando savings da área